

Exercice n° 1. Préambule python

On utilisera les packages suivants : `matplotlib`, `numpy`, `scipy` et `math`. On commencera les fichiers de TP avec ce préambule :

```
import numpy as np
import numpy.random as npr
import matplotlib.pyplot as plt
import scipy.stats as stats
import math
```

Observez ce que font les instructions suivantes :

```
exemple1 = npr.random(10)
exemple2 = npr.choice(exemple1, size=(2,3), replace=False)
exemple3 = npr.choice([0,3,4],10,p=[1/4,1/4,1/2])
x = np.linspace(-3, 3, num=100)
```

```
plt.figure()
plt.subplot(2,2,1)
plt.title("Densité")
plt.plot(x, stats.norm(loc=0, scale=1).pdf(x))
plt.xlabel("x")
plt.ylabel("Probabilité")
```

```
plt.subplot(2,2,2)
plt.title("Fonction de répartition")
plt.plot(x, stats.norm.cdf(x))
plt.xlabel("x")
plt.ylabel("Probabilité")
```

```
prob = np.linspace(0, 1, num=100)
plt.subplot(2,2,3)
plt.title("Fonction quantile")
plt.plot(prob, stats.norm.ppf(prob))
plt.xlabel("Probabilité")
plt.ylabel("x")
```

```
n = 10; p = 1/2;
x = range(n+1)
```

```
plt.subplot(2,2,4)
```

```
plt.title("Fonction de masse")
plt.vlines(x, 0, stats.binom(n, p).pmf(x))
plt.xlabel("x")
plt.ylabel("Probabilité")
plt.show()
```

```
XY = npr.normal(size=(2,100))
```

```
plt.figure()
plt.title("Nuage de points des données")
plt.scatter(XY[0,:], XY[1,:])
plt.xlabel("x")
plt.ylabel("y")
plt.show()
```

Exercice n° 2. Inversion

En utilisant la méthode par inversion de la fonction de répartition, simuler un échantillon $(X_1, \dots, X_n)$ et comparer la fonction de répartition théorique à la fonction de répartition empirique lorsque $n = 100$ puis $n = 1000$ et X_1 est :

1. de loi exponentielle de paramètre 1.5,
2. de loi de Pareto de paramètre 2.

Exercice n° 3. Loi forte des grands nombres

Soit $(X_i)_{i \geq 1}$ une suite de variables aléatoires i.i.d. d'espérance finie. On note $\bar{S}_n := \frac{1}{n} \sum_{i=1}^n X_i$. La *loi forte des grands nombres* affirme que :

$$\mathbb{P}(\bar{S}_n \xrightarrow[n \rightarrow +\infty]{} \mathbb{E}[X_1]) = 1 .$$

L'objectif de l'exercice est d'illustrer ce résultat. Tracer plusieurs réalisations de $\bar{S}_1, \dots, \bar{S}_{1000}$ lorsque les X_i sont de loi de

1. Bernoulli de paramètre 2/5.
2. Poisson de paramètre λ (essayer divers λ).
3. Uniforme sur $[0, 1]$.
4. Cauchy (on peut utiliser `stats.cauchy.rvs(size=N)` comme générateur ou utiliser la méthode par inversion de la fonction de répartition).

Exercice n° 4. Théorème central limite

On reprend les notations de l'exercice 3. Pour les trois premiers exemples de cet exercice, simuler $N = 1000$ réalisations indépendantes de $\sqrt{\frac{n}{\text{Var}(X_1)}}(\bar{S}_n - \mathbb{E}(X_1))$ pour $n = 100$ et comparer la fonction de répartition empirique de cet échantillon à la fonction de répartition de la loi gaussienne centrée réduite.

Exercice n° 5. Borel-Cantelli

Soit $(X_i)_{i \geq 1}$ une suite de variables aléatoires indépendantes de loi de Bernoulli, où X_i est de pa-

paramètre p_i . Tracer dans une même fenêtre, sur trois graphiques distincts, une trajectoire des X_i jusqu'à $i = 1000$ (c'est à dire une réalisation du vecteur $(X_1, \dots, X_{1000})$ pour :

1. $p_i = 3/4$
2. $p_i = \frac{1}{i}$
3. $p_i = \frac{1}{i^2}$

Répéter plusieurs fois la simulation. Comparer au résultat de TD correspondant.

Exercice n° 6.

Soit $(X_i)_{i \geq 1}$ une suite de variables aléatoires i.i.d. de loi de Bernoulli de paramètre p . Soit $Y := \inf\{i \in \mathbb{N}^* \text{ t.q. } X_i = 1\}$.

1. Écrire une fonction prenant en entrée les paramètres N et p et donnant en sortie N réalisations indépendantes de la loi de Y .
2. Quelle est la loi de Y ? Tester votre fonction comme dans l'exercice 2.
3. Tester votre fonction en superposant les fréquences empiriques d'un grand échantillon de la loi de Y et les probabilités théoriques données par la loi de Y (Utiliser les fonctions `unique` de `numpy` pour obtenir les fréquences empiriques et `geom.pmf` de `scipy.stats` pour la distribution théorique).

Exercice n° 1. Urne de Polya

On considère le modèle de l'urne de Polya vu en TD. On note X_n la proportion de boules rouges dans l'urne au temps n .

1. Pour $r = 1$ et $b = 1$, simulez 5 trajectoires indépendantes de la chaîne $(X_n)_{n \geq 0}$, jusqu'au temps 1000 et représentez-les sur un même graphique.
2. Estimez la loi de X_{100} à l'aide d'un échantillon de taille 1000, et comparez sa fonction de répartition à celle d'une loi $Beta(r, b)$. Répétez cette opération pour différentes valeurs de r et b .

Exercice n° 2. Wright-Fisher

Soit $N \in \mathbb{N}^*$. On étudie l'évolution au cours du temps d'une population de taille constante N constituée d'individus de deux types, A et B . Les types des individus de la $(n + 1)$ -ième génération sont obtenus à partir de la n -ème génération de la manière suivante :

Pour i allant de 1 à N , l'individu i de la $(n + 1)$ -ème génération choisit un parent au hasard uniforme dans la n -ème génération et copie son type. Tout ceci se fait indépendamment des autres individus.

On note X_n le nombre d'individus de type A dans la n -ème génération.

1. Pour $N = 5, 10, 30$, simuler plusieurs trajectoires partant de différentes valeurs de X_0 dans $\{0, \dots, N\}$.
2. Pour $N = 10$, estimer la fonction $x \mapsto \mathbb{P}_x(X_\infty = N)$ et comparer, sur un même graphique, l'estimation avec la valeur théorique qui est x/N .
3. On note T_N le temps d'absorption de la chaîne, c'est à dire le temps d'atteinte de 0 ou N . Estimer la fonction $x \mapsto \mathbb{E}_x[T_N]$ pour $N = 20$.

Exercice n° 3.

On considère la chaîne de Markov vue en TD dont l'espace des états est $\{1, \dots, 6\}$ et la matrice de transition est

$$\begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 1/4 & 1/2 & 1/4 & 0 & 0 & 0 \\ 0 & 1/5 & 2/5 & 1/5 & 0 & 1/5 \\ 0 & 0 & 0 & 1/6 & 1/3 & 1/2 \\ 0 & 0 & 0 & 1/2 & 0 & 1/2 \\ 0 & 0 & 0 & 1/4 & 0 & 3/4 \end{pmatrix}.$$

On note $C = \{4, 5, 6\}$. Dans toute la suite, on suppose que la chaîne part d'un état x fixé :

$$P(X_0 = x) = 1.$$

1. Ecrire une fonction qui prend en entrée x et n , et donne en sortie une simulation d'une trajectoire $(X_0, \dots, X_n)$ de la chaîne issue de $X_0 = x$. On pourra utiliser la fonction `npr.choice` pour tirer au hasard un entier selon la loi donnée par une ligne de la matrice ci-dessus.

2. Déterminer la mesure de probabilités invariante μ de la chaîne restreinte à C à l'aide de la fonction `np.linalg.eig`.
3. Lorsque $x \in C$, vérifier expérimentalement que la loi de X_n converge lorsque $n \rightarrow +\infty$ vers μ : on superposera la probabilité empirique (sur un échantillon de taille 1000) pour X_n de prendre les valeurs 4, 5 ou 6 avec les valeurs de (μ_4, μ_5, μ_6) . On effectuera ceci pour $n = 1, n = 5, n = 20$.
4. Estimer, sur la base d'un échantillon de taille 1000 de trajectoires de la chaîne, la probabilité d'absorption par 1 et par C en partant de $x = 2$, puis de $x = 3$. Comparer ces valeurs aux valeurs théoriques vues en TD.

Exercice n° 4. Ehrenfest

On considère le modèle de l'urne d'Ehrenfest à N particules et on suppose que N est pair. On note $(X_N(t))_{t \geq 0}$ la chaîne de Markov associée à espace d'états $\{0, \dots, N\}$.

1. Représentez des trajectoires de longueur 1000 de cette chaîne partant de $X_N(0) = 0$ et pour $N = 10, 100$ et 1000.
2. Lorsque $N = 6$, déterminer numériquement la mesure de probabilité invariante en résolvant un système linéaire, et comparez-la à la loi stationnaire calculée en TD.
3. Lorsque $N = 6$, comparer la distribution empirique de $(X_N(0), \dots, X_N(1000))$ à la loi stationnaire.
4. Lorsque $N = 200$, estimez la loi de $X_N(1000)$ sur la base de 500 simulations et comparez-la à la loi stationnaire, en comparant les fonctions de répartition. Y a-t-il convergence de la loi de $X_N(t)$ vers la loi stationnaire lorsque t tend vers l'infini ?
5. Pour N allant de 100 à 500 par pas de 100, estimez l'espérance du temps d'atteinte de $N/2$ partant de 0 sur la base d'un échantillon de taille 500. Comparer au résultat théorique concernant l'espérance du temps de retour en 0 partant de 0 et commenter.

Exercice n° 1. Régression linéaire (cf. exo de TD sur les eucalyptus)

Récupérer les fichiers de données (circonférences et hauteurs) aux adresses suivantes :

https://www-fourier.ujf-grenoble.fr/~rossigno/Enseignement/ens_files/circ.txt

https://www-fourier.ujf-grenoble.fr/~rossigno/Enseignement/ens_files/h.txt

1. Représenter les données sous la forme d'un nuage de points (hauteur en fonction de la circonférence).
2. Effectuer une régression affine et représenter sur le graphique :
 - la droite de régression,
 - deux autres droites, parallèles à la droite de régression, et telles que 80% des points soient situés entre ces deux droites.
3. Calculer le coefficient de corrélation entre la hauteur et sa "prédiction affine".

Exercice n° 2. Comparaison de moyennes pour des échantillons gaussiens de même variance

On traite 12 parcelles de terrain identiques avec un engrais A et 12 autres avec un nouvel engrais B. On obtient avec A une production moyenne de 4,8 quintaux avec un écart-type empirique observé égal à 0,36. Les quantités correspondantes pour B valent 5,7 et 0,4. On modélise cette expérience comme en TD.

1. Donner la valeur observée sur ces données pour l'intervalle de confiance construit en TD, au niveau 95%.
2. Pensez-vous que l'on puisse considérer les espérances de production comme différentes selon qu'on utilise l'engrais A ou l'engrais B ?

Exercice n° 3. Estimation

On peut construire plusieurs intervalles de confiance pour le paramètre p de la loi binomiale de paramètres n et p , sur la base de l'observation d'une variable aléatoire X de loi binomiale¹ de paramètres n et p :

1. en notant q_α le quantile d'ordre α de la loi $\mathcal{N}(0,1)$, un intervalle de confiance $[\frac{X}{n} \pm \frac{q_{1-\alpha/2}}{2\sqrt{n}}]$ dont on contrôle le niveau asymptotique (au moins $1 - \alpha$) grâce au théorème central limite,
2. celui de niveau $1 - \alpha$ qu'on peut obtenir grâce à l'inégalité de Tchebychev : $[\frac{X}{n} \pm \frac{1}{2\sqrt{n\alpha}}]$.

Pour différentes valeurs de n (par exemple, $n = 30$, $n = 100$ et $n = 1000$ ou 10000) et pour p variant de $\frac{5}{n}$ à $\frac{1}{2}$, déterminer une approximation numérique de la probabilité que p appartienne à chacun de ces intervalles de fluctuation, au niveau 95%. Pour chaque valeur de n , vous représenterez les résultats sur la forme d'un graphique, en traçant, en fonction de p , la probabilité évoquée.

1. ou encore pour le paramètre p de la loi de Bernoulli de paramètre p sur la base de l'observation d'un échantillon de taille $(X_1, \dots, X_n)$, et en posant $X = \sum_{i=1}^n X_i$